

Lexus 流失風險洞察與智慧溝通 | 專案大綱與系統架構 (草案)

2026-09-23 · 數字更新 2026-09-25 · 時程改為 Sprint 架構)

題目：題 3「AI 流失風險洞察與智慧溝通：打造 Lexus 車主忠誠度的終極防線」
目標使用者：Lexus 售後服務部門決策者
初賽：10/14 13:00 前上傳簡報 (15 頁內 + 提案摘要頁) | 決賽：11/21 現場 Demo Prototype

0. 目前進度

階段	狀態	產物
資料蒐集 (PTT / Mobile01 / Dcard)	✅ 完成	data/{ptt,mobile01,dcard}/ · 5,765 篇、22.5 萬則留言
前處理 (合併、過濾、去重、切句)	✅ 完成	data/processed/sentences.jsonl 235,775 句；售後句 21,183 句
流失意圖粗標 (Haiku 初篩 + 強模型帶上下文複核)	✅ 完成	21,183 句全部複核 (Mobile01、PTT 用 Claude Sonnet；Dcard 5,355 句於 9/24 改用 Cursor GPT-5.6 Sol 補完，重疊 3,760 句的 $c \geq 2$ 一致率 98.4%、 κ 0.447)。 churn_positives.jsonl 1,671 句 (考慮離開 1,063 / 已離開 608)。詳見 reports/T1_dcard_verify_report.md
面向標註 (服務體驗、零件保修...) 全量	✅ 完成	aspect_labels.jsonl 21,183 句 (缺 0)。Sonnet 帶上下文；試標 600 句 Haiku 對 Sonnet 面向 F1 0.60，故全量用 Sonnet。流失率最高 (分母為全部 21,183 句)：零件供應 17% (139 / 803)、價格 15% (587 / 3,908)
替代選項、車主特徵抽取	✅ 完成	同檔。流失句 1,671：一般外廠 736、自備料 234、DIY 135；保固 out 62 / in 17；車型 RX 191、ES 142、IS 119
流失原因「其他」細分	✅ 完成	396 句「其他」以 GPT-5.6 Sol 細分寫入欄位 t2：品質 40、價格 32、非售後原因 27、便利設施 12、報價透明 10；殘餘「無明確原因」252 句再拆 (T3)：外廠推薦 88、疑似誤標 57、自行處理 49、外廠詢問 49、離開品牌 5，真正無資訊只剩 4 句。詳見 reports/T2_other_refine_report.md、T3_residual_split_report.md
人工標註集	✅ 完成 (9/29)	300 句 (隨機 150 + 困難 150)，A/B κ 0.40，仲裁後為金標。隨機層以人工為準：r4 F1 0.82 / κ 0.81 與 Sonnet 相同，Haiku F1 0.50；正例僅 9 句，召回 CI 0.45–0.94。困難層所有模型 $F1 \leq 0.51$ ，r4 偏多報 (精確率 0.34)。reports/T9_human_eval.md

階段	狀態	產物
自訓模型 (L3) 本機 QLoRA	✅ 正式 版 r4	jev 官方 API 無法申請，改用 LLM2Jev 式 prefill-only 決策模型 + 本機 QLoRA (RTX 4060 Ti 8 GB · VRAM 4.7 GB) 。600 句測試集 (Sonnet 為金標) 流失 $c \geq 2$: r4 (4B · 520 正例過採樣四成 + 1,560 負例 · 2 epoch) P 0.62 / R 0.77 / F1 0.685 · κ 0.64 · 四類準確率 0.80 ；同一測試集 Haiku 零樣本 F1 0.58 / κ 0.53 · r2 F1 0.60 / κ 0.51 。每句 0.7 秒、零 API 費。adapter D: \hf_cache\lora\qwen3-4b-churn-r4-ep2 。詳見 reports/T4-T6、T8_*.md、jev 評估_2026-09-24.md
Persona、風 險機制、溝通 生成、 Prototype	🟪 未做	產出 1、產出 2 主體
官方解題資源 (保修服務網 頁、車主手 冊)	❓ 待確 認	報名後寄信；溝通生成 RAG 的知識庫

結論：標註層 L2a–2d 已完成且 21,183 句全部複核，下一步是人工標註集與 L3/L4/L5。

0.1 標註層初步洞察

更新於 2026-09-24 (reports/T1_dcard_verify_report.md、T2_other_refine_report.md)。21,183 句售後句全部經強模型複核，流失率分母直接用全量；Mobile01、PTT 由 Claude Sonnet 複核，Dcard 5,355 句由 Cursor GPT-5.6 Sol 補複核，兩模型在 3,760 句重疊樣本的 $c \geq 2$ 一致率 98.4%。

1. 零件供應與價格是流失率最高的面向。零件供應 17% (139 / 803，勝算比 2.58，95% CI 2.13–3.11)、價格 15% (587 / 3,908，勝算比 2.64)；銷售交車最低 (1%，勝算比 0.15)。 χ^2 皆 $p < .001$ (reports/T7_stats_tests.md)。
2. 高負面不等於高流失。報價透明負面 73%、流失 9.5%；態度負面 61%、流失 4.7%。銷售交車負面 44%，流失只有 1.4% (19 / 1,367)。(分母全部 21,183 句，2026-09-27 重算) 被推銷、被當盤子傷信任，但「貴」和「等料」才讓人真的離開。
3. 替代選項仍壓倒性流向一般外廠。流失句 1,671 中：一般外廠 736、自備料 234、DIY 135、他牌或換車 70、技師開業 40、連鎖保養 8 (排序自初步至今未變)。
4. 標得到保固的流失句，過保遠多於保固內。out 62 vs in 17。
5. Dcard 流失率確實較低，不是標註缺口。補複核後 Dcard 流失句 73→138，流失率 2.5% (138 / 5,481)，仍遠低於 Mobile01 10.6% (1,081 / 10,224) 與 PTT 8.3% (452 / 5,478)。作者層級 (主結果)：Mobile01 18.2%、PTT 14.1%、Dcard 6.8%， $\chi^2(2)=99.5$ ， $p < .001$ ，Cramér's V=0.125 (小效果)，三組兩兩皆顯著 (Bonferroni)。Dcard 用戶偏購車階段，Persona 要註明來源偏差。車型以 RX 191、ES 142 最多，IS 119 第三。
6. 流失原因四分之一原本標為「其他」，細分後多數仍無明確原因。396 句「其他」拆出品質 40、價格 32、非售後原因 27 等，但 252 句只是推薦或詢問外廠、沒講為什麼。再拆後：外廠推薦 88、外廠詢問 49、自行處理 49，合計 186 句是「已經在找出口但沒抱怨」的靜默流失，溝通策略要另外設計，不能只靠痛點回應。另有 57 句連前後文都看不出流失意圖 (疑似誤標)，清單在 T3 報告，人工標註時優先複查。

1. 題目要求 → 本案對應

題目要求	本案做法	對應產出
「服務體驗」「零件保修」自動化標籤與語意分析	L2 面向標註 + L3 自訓分類器	產出 1
描繪顧客樣貌、建構 Persona	L5 作者層級分群 + LLM 敘事	產出 1
流失風險因素：替代選項、考量點、高風險族群輪廓	L2 替代選項 / 特徵抽取 + L4 風險辨識機制	產出 1
說明使用了哪些 AI 技術 / 模型	全流程技術架構圖 (見 §2)	產出 1
針對 Persona 的溝通策略、AI 生成內容範例	L6 RAG 溝通內容生成	產出 2
精準接觸點規劃、AI 方案運作流程圖	L7 觸發規則 × 接觸點 × KPI	產出 2

2. 系統架構 (七層)

[L0 蒐集]	PTT / Mobile01 / Dcard 爬蟲 (已完成)
[L1 前處理]	合併 → 看板/分類過濾 → 切句 → 去重 → 售後關鍵詞篩選 (已完成)
[L2 標註層]	LLM 自動標註 ├─ 2a 流失意圖 0 - 3 + 說話立場 (已完成) ├─ 2b 面向：服務體驗／零件保修／價格／維修品質／等待／銷售交車…+情緒 ├─ 2c 替代選項：連鎖保養廠／原廠技師開的店／DIY／自備料／他牌原廠／換車 └─ 2d 車主特徵：車型、車齡或是否過保、里程、地區、新車或二手
[L3 自訓模型]	以 LLM 標註結果訓練輕量分類器 + 人工標註 300 句評估 (F1) → 可持續監測、低成本、可解釋
[L4 風險辨識機制]	句 → 作者 → 族群 三層風險分數 規則訊號 (過保、價格抱怨、詢問外廠…) × 模型分數 → 高/中/低 + 「公開輿情訊號 → Lexus CRM 欄位」對照表 (落地關鍵)
[L5 洞察與 Persona]	作者層級特徵分群 → LLM 生成 Persona 敘事、高風險議題、趨勢
[L6 溝通生成]	RAG：Persona × 痛點 × Lexus 官方保修知識庫 → 各接觸點內容 事實查核護欄 (價格、保固條款只能引用知識庫)
[L7 接觸點與流程]	觸發事件 → 判定 Persona → 產生內容 → 投遞渠道 → KPI 回饋

各層技術選型 (初版)

層	技術	備註
L2	Claude Haiku 初篩 + Sonnet 帶上下文複核	已驗證：Haiku 單獨召回約 57% · 需兩段式
L3	Qwen3-4B 4-bit QLoRA 的 System-One 決策模型 (prefill-only 輸出各等級機率，本機 8 GB 顯卡可訓可推)，以 21,183 句 LLM 標籤為監督；BERT 類微調保留為對照或備案	「LLM 標註 → 自訓決策模型 → 校準機率」是技術厚度賣點；首版已追平 Haiku 初篩
L4	規則權重 + L3 機率分數，作者層級彙總	必須可解釋，給售後主管看得懂

層	技術	備註
L5	特徵向量 (面向分布、立場、車齡...) → K-means / HDBSCAN → LLM 命名與敘事	Persona 每項描述都要能回溯到原句
L6	Claude + 官方保修文件向量檢索	解題資源到手後建知識庫
Prototype	儀表板 (議題熱度、趨勢、Persona、風險語料) + 溝通內容生成器	決賽 Demo 20% 作品完成度

3. Persona (9/26 PO 決定 4 個：過保精算派、品質失望派、靜默出走者、口碑建議者；刪單族併入精算派、技術 DIY 派併入靜默出走者)

從目前 1,671 句正例的初步觀察，先列假設，最終以分群結果為準：

假設 Persona	資料線索	流失型態
過保精算派 (511 人，39.9%)	面向價格 48%；替代一般外廠 21%、自備料 17%；過保比例 15.7% 為四組最高	過保後整體轉外廠或自備料
品質失望派 (247 人，19.3%)	面向技術品質 43%；替代他牌或換車 10% 為四組最高；「原廠查不出來」「處理不好就去外場」	因信任破裂離開，甚至換品牌
口碑建議者 (195 人，15.2%)	立場「建議他人」61%；Dcard 占比最高 (49 人)	本身不一定流失，但會帶走別人
靜默出走者 (128 人，10.0%)	替代一般外廠 55%；t2 外廠詢問 / 推薦為主；p_churn 平均 0.75 為四組最高；分群獨立支持 (78% 集中)	沒有痛點訊號就離開，最難靠客訴系統攔截
未分類 (199 人，15.5%)	只抱怨態度、保固內說不回廠、零件詢問	規則初版未覆蓋，Sprint 2 決定併入或新增

4. 產出對應與簡報骨架 (15 頁內)

頁	內容	來源層
摘要	提案摘要頁 (7 欄位不得改名改序)	—
1	痛點 (9/26 定稿)：「每 6 位在論壇談 Lexus 售後的車主就有 1 位已在找出口，而且大多沒有抱怨」(作者層級 Mobile01 18.2%；靜默出走 186 / 1,671)	L2、T7 檢定
2	資料規模：三站、23.6 萬句、1,671 句流失語料	L0-L2
3	AI 系統架構圖	§2
4	標註與模型：兩段式 LLM + 自訓模型 + F1	L2-L3
5	市場輿情總覽：面向分布、趨勢、來源	L5
6	高風險議題分析	L4-L5
7	替代選項地圖：流去哪裡、為什麼	L2c

頁	內容	來源層
8–9	Persona (3–4 個，含代表原句)	L5
10	流失風險辨識機制與 CRM 對照	L4
11	核心溝通策略：傳遞「原廠服務價值」	產出 2
12	AI 生成內容範例 (Persona × 接觸點)	L6
13	接觸點規劃與觸發時機	L7
14	AI 方案運作流程圖	L6–L7
15	預期效益、KPI、導入時程	產出 2

5. 短衝 (Sprint) 架構 (2026-09-25 依 iPAS 指引 Scrum 框架改寫)

官方節點：10/14 (三) 13:00 初賽繳件截止 → 10/28 (三) 入圍公告 (15 組) → 11/07 (六) 決賽工作坊 (過半隊員須到) → 11/18 (三) 23:59 決賽 30 頁簡報繳交 → 11/21 (六) 現場簡報 + Demo。原則：每個 Sprint 有一個可量測的 Sprint Goal、一份 Sprint Backlog、一個可展示的 Increment；沒達 Goal 不往下一階段硬推，回到 Backlog 重排。

5.1 角色與節奏

Scrum 元素	本案對應
Product Owner	B (落地)。代表評審與 Lexus 售後決策者的觀點，負責 Product Backlog 優先序與 Sprint Review 驗收
Scrum Master	A (技術)。維持節奏、清除障礙 (環境、資料、工具)
Development Team	A、B，加上 AI 代理 (Claude 當 Coordinator，Orca worker 負責批次標註、訓練、報告產出)。兩人團隊角色兼任
Sprint 長度	初賽前 3–4 天一個 Sprint (時間緊)；決賽前 1–2 週一個 Sprint
Daily Scrum	每晚 21:00，15 分鐘，三題：昨天做了什麼、今天做什麼、卡在哪
Sprint Review	Sprint 最後一天，對照 Definition of Done 逐項驗收 Increment
Sprint Retrospective	Review 後 10 分鐘，只記一件要改的事
工具	Product Backlog 與 Sprint Backlog 記在本文件；任務追蹤用 GitHub Issues；產出物在 reports/

5.2 Product Backlog (依優先序，PO 可重排)

ID	項目	層	狀態
PB-01	21,183 句流失與面向標註全部複核	L2	✅ 完成 (T1-T3)
PB-02	去識別化流程與去識別版語料 (簡報、Demo 只用此版)	資料治理	✅ 完成 (T7，517 次遮蔽、抽查 50 句漏網 0)
PB-03	來源與面向流失率的比例檢定、效果量、信賴區間 (句子與作者兩層)	統計	✅ 完成 (T7，作者層級 $\chi^2=99.5$ 、 $V=0.125$)
PB-04	資料品質檢核表 (缺失、重複、一致、異常、完整)	L1	✅ 完成 (T7)
PB-05	L3 本機決策模型：r4 F1 0.685、召回 0.77、 κ 0.64，超過 Haiku	L3	✅ 完成 (T8)
PB-06	人工標註 300 句、A/B κ 、三模型對人工指標	L3 評估	✅ 完成 (9/29，reports/T9_human_eval.md；面向未仲裁，只用兩人一致句)
PB-07	官方解題資源整理：保固年限、定保價格、原廠 vs 外廠價差	L6 前置	🟡 公開版完成 (T11：官網知識庫 40 條 knowledge/；口述價差表 488 筆)；資料信 9/26 仍未到，收到後補車主手冊與定保官方價
PB-08	「輿情訊號 → CRM 欄位」對照表	L4	✅ 完成 (9/29 PO 定案：欄位維持業界假設、R7 只作驗證、門檻先用初版；輿情訊號對應 CRM 欄位_草稿_2026-09-28.md，簡報 P8)
PB-09	L4 風險分數 (規則 R1-R8 × r4 機率) → 作者層級高 / 中 / 低	L4	✅ 初版完成 (T10：6,394 作者，高 1,049 / 中 231 / 低 5,114；高風險作者 74% 有金標流失句，低風險 1.8%)
PB-10	L5 高 / 中風險作者規則指派 4 個 Persona，K-means 驗證，每項描述可回溯 deid 原句	L5	✅ 初版完成 (T10b：過保精算派 511、品質失望派 247、口碑建議者 195、靜默出走者 128、未分類 199；分群只獨立支持靜默出走者，ARI 0.08)
PB-11	洞察圖表：面向流失率、來源流失率、替代選項、風險×來源、Persona×面向、r4 校準、Persona 規模	產出 1	✅ 初稿 F1-F7 (reports/figures/)，Sprint 2 依 PO 選圖精修
PB-12	L6 RAG 知識庫 + Persona × 接觸點生成範例 + 事實查核護欄	L6	🟡 Sprint 3
PB-13	L7 觸發規則 × 接觸點 × KPI、AI 方案運作流程圖	L7	🟡 Sprint 3
PB-14	15 頁初賽簡報 PDF + 提案摘要頁 + 3 分鐘影片，10/10 上傳	繳件	🟡 Sprint 3
PB-15	可行性、風險矩陣、KPI 三層級、導入時程頁 (iPAS 骨架)	簡報	🟡 Sprint 3

ID	項目	層	狀態
PB-16	Prototype 儀表板 (角色切換、時間過濾、點選看去識別原句)	決賽	 Sprint 4–5
PB-17	端到端 Demo：新留言 → 風險機率 → Persona → 生成內容 → 人工審核	決賽	 Sprint 5
PB-18	Model Card、資料血緣圖、匿名化紀錄 (附錄)	治理	 Sprint 4
PB-19	30 頁決賽簡報 (11/18)、現場排練	決賽	 Sprint 6–7

5.3 Sprint 計畫

Sprint 0 | 9/24–9/28 | 「資料可信、可安全引用，L3 首版成立」 (進行中)

項目	負責	Definition of Done
PB-01 全量複核	AI 代理	✅ 21,183 句皆有複核；報告 T1–T3
PB-05 L3 r2	AI 代理	✅ 600 句測試 F1 0.60 / κ 0.51，追平 Haiku
PB-02 去識別化	AI 代理→A 驗收	✅ churn_positives_deid.jsonl 產出；抽 50 句漏網 0；流程在 reports/T7_deid_report.md
PB-03 統計檢定	AI 代理→B 驗收	✅ reports/T7_stats_tests.md；作者層級為主結果
PB-04 品質檢核表	AI 代理	✅ reports/T7_data_quality.md
PB-05 r4 訓練	AI 代理	✅ F1 0.685、召回 0.77，取代 r2 (reports/T8_r4_report.md)

Review 9/28：三份新報告齊備，B 確認去識別例句可放簡報。(9/25 已全部完成，Sprint 0 提前收斂；剩餘時間用於 B 預讀報告與準備 Sprint 1 標註指引。)

Sprint 1 | 9/29–10/1 | 「人工標註定案，模型指標有人工金標」

項目	負責	Definition of Done
PB-06 標註指引與抽樣	AI 代理 (已完成 9/26)	標註指引_2026-09-29.md；data/processed/human_labeling_A.xlsx、_B.xlsx (校準 30 + 正式 300)；候選池為 r4 未見過的 1,696 句，隨機層 150 (母體估計) + 困難層 150 (r4 或 Haiku 與金標不一致、疑似誤標、r4 不確定)
PB-06 校準與標註	A、B	先各標「校準30」對答案、補邊界例，再各自獨立標「正式300」(約 90 分鐘)；python pipeline/human_eval.py 產生仲裁表，一起定最終標籤
PB-06 評估	AI 代理	python pipeline/human_eval.py --final → reports/T9_human_eval.md：A/B κ ；Sonnet / GPT、Haiku、r4 對人工的 P/R/F1/ κ ，分隨機層與困難層
PB-07 解題資源	B	保固年限、定保價格、原廠 vs 外廠價差表

項目	負責	Definition of Done
PB-08 CRM 對照表	B	每個輿情訊號對應一個 CRM 可觀測欄位 (保固到期、回廠間隔、刪項)

Review 10/1：指標表定稿；若 $A/B \kappa < 0.6$ ，Retro 決定是否縮小標籤集。

Sprint 2 | 10/2–10/5 | 「產出 1 完成：每個數字有檢定或原句支撐」

項目	負責	Definition of Done
PB-09 風險分數	A + AI 代理	作者層級名單，高 / 中 / 低各附規則命中與模型機率；可解釋
PB-10 分群與 Persona	A 分群、B 敘事	3–4 個 Persona，每個含代表原句 (去識別)、規模、主要面向、替代去向
PB-11 圖表	AI 代理→B 選圖	依資料型態選圖 (長條、折線、熱力圖)；顏色語意一致
PB-03 檢定寫入	A	洞察頁每個比較附 p 值、效果量、CI

Review 10/5 (中期檢查)：產出 1 所有頁面內容凍結；Persona 無資料支撐者刪除。

Sprint 3 | 10/6–10/10 | 「產出 2 與繳件」

項目	負責	Definition of Done
PB-12 RAG 生成	A + AI 代理	知識庫建好；每個 Persona × 2 個接觸點各 1 則範例；價格與保固條款只引用知識庫，附查核紀錄
PB-13 觸發與流程圖	B	觸發事件、判定、生成、投遞、KPI 回饋一張圖；含人工審核節點
PB-15 iPAS 骨架頁	B	可行性四面向、風險矩陣、KPI 三層級、五階段導入時程
PB-14 簡報與影片	A 技術頁、B 其餘	15 頁內 + 摘要頁；影片 3 分鐘、YouTube 不公開、標題格式合規
上傳	隊長	10/10 上傳 PDF + 影片連結，送出「請求更新」

Review 10/10：兩人各自從評審角度打一次分；10/11–10/14 只做修正重傳。

Sprint 4 | 10/15–10/28 | 「等待公告期：Prototype 骨架」 (低強度，1 週一次同步)

項目	負責	Definition of Done
PB-16 儀表板框架	A	前端可載入去識別資料，四個頁籤：總覽、面向、Persona、風險名單
L3 全量推論	AI 代理	21,183 句都有 r2/r4 機率，供儀表板用
PB-18 Model Card 與資料血緣	AI 代理	一頁 Model Card；資料血緣圖 L0→L7

Sprint 5 | 10/29–11/07 | 「端到端 Demo 可演示」 (入圍才啟動)

項目	負責	Definition of Done
PB-17 即時推論	A	貼一則新留言，2 秒內回風險機率、Persona、建議接觸點
PB-17 生成與審核	A + B	生成內容進審核佇列，人工核准後才「投遞」
工作坊準備	B	三個最想問業師的問題；一頁現況摘要

Sprint 6 | 11/08–11/18 | 「依業師建議優化，決賽簡報繳交」

項目	負責	Definition of Done
業師建議收斂	B	建議分「必改 / 可改 / 不改」三類，必改項排進本 Sprint
Prototype 完成度	A	Demo 腳本 8 分鐘，兩次完整跑過無錯
PB-19 決賽簡報	A、B	30 頁內，11/18 前上傳

Sprint 7 | 11/19–11/21 | 「排練與現場」

排練兩次（一次計時、一次故障演練：網路斷線改用本機模型與離線資料），11/21 現場簡報與 Demo。

5.4 初賽繳件清單

項目	說明
步驟一：報名	✅ 9/23 已完成
提案簡報	依官方模板製作，以 PDF 上傳；15 頁內（不含附錄），另加提案摘要頁
方案說明影片	3 分鐘內，YouTube 不公開，標題「LEXUS_作品名稱_2026 和泰 AI 黑客松」，連結須維持到 11/21
表單欄位	團隊名稱、作品標題、選定主題（題 3 LEXUS）

6. 待決事項與風險

- 1. 解題資源是否已收到？L6 需要官方保修網頁與車主手冊當知識庫。
- 2. 人工標註由誰做？建議 A、B 兩人各自獨立標同一批 300 句，計算兩人一致性 (κ) 與 LLM 的準確率、召回率、F1，才能說服評審標註可信。
- 3. 公開輿情 ≠ Lexus 車主資料：風險機制必須寫成「輿情訊號 → 對應 CRM 欄位」的遷移方案（保固到期、回廠間隔拉長、刪減項目），否則可行性會被質疑。
- 4. 正例來源偏 Mobile01 (67%)：Persona 要註明來源偏差，Dcard 用戶多在購車階段。
- 5. 流失原因「其他」已細分完成 (9/24，T2 + T3)，真正無資訊只剩 4 句。T3 揪出 57 句疑似誤標（占流失句 3.4%），人工標註 300 句時把這 57 句納入，順便估計流失標註的精確率。
- 6. 兩個複核模型並存：Mobile01、PTT 是 Sonnet，Dcard 是 GPT-5.6 Sol。簡報技術頁要揭露，並附 3,760 句重疊一致率作為可比性證據。
- 7. L3 自訓模型下一步：r2 召回只有 0.55，主因是負例太多讓模型偏保守（r3 全量更嚴重，召回 0.29）。可試：正例過採樣到四成、2 epoch、或 4B 用 r1b 的 3 倍負例配方；並把面向九題一起微調。人工標註 300 句完成後，用人工標籤重算所有模型的指標，Sonnet 也不再是金標。